

Relatório 11 - Prática: Lidando com Dados do Mundo Real (II)

João Pedro Gomes


1. Introdução

O card 11 pede pra assistirmos vários videos, que explicam sobre como lidar e tratar dados e depois fazermos esse relatório explicando as tecnicas que eles ensinam.

2. Desenvolvimento

K Nearest Neighbours:

Ele começa explicando essa técnica pra classificar um novo dado, em um conjunto com dados categorizados aparece um novo dado sem categoria aí o sistema analisa os K vizinhos mais próximos pra definir a categoria, vamos supor q o K é igual a 3, ele olha os 3 vizinhos próximos e olha as categorias deles e decide como a que mais aparece como a categoria do dado novo.



PCA – Principal Component Analysis:

Cada dado tem dimensões, por exemplo, um livro tem titulo, subtítulo, texto da contra capa, editora, etc..., cada uma dessas características é uma dimensão, mas se um objeto tem muitas dimensões fica difícil de visualizar aí vem o PCA, que diminui elas mas tentando manter o máximo da variação dos dados originais. Igual o exemplo no vídeo das flores, o dataset tem 4 dimensões, e o PCA diminui pra 2 pra visualizar em um gráfico.


Data warehousing, ETL e ELT:

Um data warehousing é um lugar com um monte de servidores onde várias empresas guardam dados pra que analista de dados possam usar.

Pro dado ir pra esse lugar se passa por um tratamento, antes ou depois de armazenar ele, pra tudo ficar padronizado, como data, distancia, tempo, etc..., e pra isso existem os metodos ETL e ELT.

O ETL, Extract, pegar os dados, Transform, fazer mudanças nos dados e o L é de Load, carregar os dados pro data warehousing depois de transformados. O problema é a escalabilidade pra empresas grandes vão muitos dados e essa etapa de mudar os dados pode empacar.

O ELT é a mesma coisa só que o load vem antes do tranform, ele sobem os dados crus pro warehousing e dps transformam ai usa o processamento de varias maquinas juntas.



Reinforcement Learning:

É um metodo de treino com recompensa e punição, se o agente que é tipo o personagem faz algo bom ele ganha uma recompensa se faz algo ruim uma punição, é uma tecnica muito usada pra treinar carros autonomos, ou fazer uma maquina jogar algum jogo, etc..., pra isso se tem 3 coisas, o agente que é o personagem, no caso o pacman ou um carro, ai vem o estado que e a situação atual do agente, onde ele tá oq tem ao redor e oq ele pode fazer e as ações é oq ele pode fazer, ir pra baixo, cima, lado. Pros movimentos existe a tecnica da tabela Q, que é uma tabela onde tem todas as posições e estados e qual é o melhor caminho naquele estado 90% das vezes é usado essa tabela e 10% é randomizado uma ação pra descobrir caminhos novos. As recompensas funcionam da seguinte forma se o agente fizer algo bom ele ganha +10 pontos se fizer algo de errado -1 ou -10.

Matriz de confusão:

É uma tabela que compara a previsão do modelo com a resposta correta, para ver se ele previu a maioria certo ou errado.

Previsto	Positivo	Negativo
Sim	Real positivo	Falso positivo
Não	Falso negativo	Real negativo

O real positivo é, o dado era positivo e o modelo previu certo, o falso negativo é quando o dado era positivo e o modelo previu errado, o falso positivo é quando o dado era negativo e o modelo previu errado e o real negativo é quando o dado era negativo e o modelo previu certo.

Métricas de avaliação:

Acurácia: Ve quanto o modelo acertou, pega os reais positivos e reais negativos e divide pelo total de dados.

Precisão: Pega os positivos e ve quais estão certos, pega os reais positivos e divide pela soma de reais positivos e falsos positivos.

Recall: Ele pega os positivos reais e ve quantos o modelo acertou, ele pega os verdadeiros positivos e divide pela soma de verdadeiro positivos e falsos negativos.

F1: Pega a precisão e multiplica pelo recall e divide pela soma dos mesmos e depois multiplica 2, porque se um modelo sempre preve algo como sim ele tem 99% de acurácia, mas o f1 será 0 porque o recall para categoria não é de 0, ele é um equilíbrio entre recall e precisão.

ROC: A curva roc é uma curva q quanto mais alta o modelo classifica melhor

AUC: É a área embaixo da curva de ROC que vai de 0 a 1 ela mede o quão bem ela distingue o positivo do negativo.

Bias Variance:

É quanto as previsões estão longe do centro, pense nas previsões como tiros em um alvo, se o viés tá alto quer dizer q o modelo atira longe do centro mas com variância baixa, estão focado em um local longe do centro.

Se os tiros estão espalhados longe do centro mas não estão focados em um local só quer dizer q a variância é alta ele chuta qualquer coisa.

Existe um problema que o correto é os dois estarem baixos, mas quando se diminuiu um o outro começa a aumentar se um modelo é muito simples ele tem baixa variância mas um viés alto, se é muito complexo tem baixo viés mas muita variância.

Por isso o correto é achar o local correto e não só diminuir o vies e a variância, onde a soma dos dois dá o menor número possível.

K-fold

K-fold é a técnica pra treinar o modelo e testar ele, antes era uma divisão de 60% dos dados vai pro treino e 40 vai pros testes, aí isso pode ser ruim pois os mais difíceis no treino e os fáceis no teste que pode dar overfitting.

Aí usando essa técnica é dividido em K pastas, aí o modelo roda as K vezes e a cada vez q ele roda uma pasta é pro teste e as outras pro treino.

Exemplo, temos 5 pastas, p1, p2, p3, p4 e p5, o K é 5, no primeiro ele pega o p1 pra testar e usa resto pra treino, dps ele pega o p5 pra teste e usa o resto e assim vai indo.

Data cleaning and normalization:

Nessa aula ele fala mais sobre dados e como ajustar eles, ele começa falando de outliers que são dados que fogem do padrão, exemplo um conjunto números 1, 0.222, 0.111, 0.213, 1.000.000.000,00 claramente o último sai do padrão e seria um outlier, se treinar um modelo com esse conjunto ele vai sair errado pois tem um dado que não faz sentido.

Depois ele fala sobre o que fazer quando tem dados faltando, que normalmente se algum dado em alguma coluna ou linha está faltando existem as possibilidades de completarem com a média da coluna, se for um categórico pegar o que mais aparece, ou simplesmente excluir, depende do contexto do problema.

Uma forma de data cleaning é a padronização, que pega o seguinte, por exemplo aqui no Brasil a gente escreve dia/mes/ano em alguns países é mes/dia/ano, aí vai da opção do analista como padronizar.

E também existe o problema de escalas diferentes, onde se você treinar seu modelo pra prever preço de carro com a idade do dono e o valor do carro o modelo pode dar mais relevância ao preço por ele ser maior, aí se normaliza em uma escala de 0 a 1 pra resolver isso, se for dados de sim ou não são convertidos pra 0 e 1.

Feature engineering:

As features são as características dos dados, tipo pra prever a renda de alguém aí nos dados tem lá, altura, idade, peso, endereço, escolaridade, etc...., tem coisas que não são relevantes pra essa previsão e esses dados atrapalham na hora de treinar, e pra resolver isso se usa o PCA que eu falei mais cedo.

Balanceamento de dados:

Desbalanceamento de dados é quando se tem menos dados de um tipo, como prever se o email é spam ou não, e ter 500 que não são spam e outros 50 que são, o modelo vai aprender o padrão pelo q tem a maior frequência ele sempre vai detectar que não é spam por que tem mais dados que não são, e pra resolver existem técnicas de balanceamento.

Oversampling que é pegar os dados spam e fazer varias copias dele pro modelo dar mais atencao pra eles.

Undersampling diminui a quantidade maior de dados ou seja os que são normais passam de 500 pra 50 também.

Smote ele usa KNN que pega exemplos reais e cria novos dados sinteticos muito parecidos com os reais.

Binning, transforming, encode, scalling e shuffling:

Aqui ele passa sobre essas técnicas.

Binning: é agrupar dados em um intervalo, tipo jovens(18 – 30) adulto (31 – 60), isso serve pra que cada intervalo tenha um numero certo de pessoas.

Transforming: é usado pra deixar os dados mais faceis pra maquina entender, tipo arrumar um grafico que tem varias ondas ou tá tudo torto, aplica log q deixa mais reto, x ao quadrado ou raiz de x ajuda a maquina a pegar padroes.

Encode: o modelo não entende as categorias nomeadas ou o numero 8 que é o exemplo do vídeo, a solução é criar vários baldes vamos supor de 0 a 10, ai quando n tem numero aparecendo fica tudo zerado e quando aparece o numero 8 a caixinha do numero 8 vira 1.

Scalling: é deixar tudo na mesma escala que e oq eu disse antes de jogar tudo pra uma escala de 0 a .

Shuffling: é embaralhar os dados, se o dataset tá ordenado o shuffling desordena ele todo pro modelo entender que a ordem não importa.

Pra minha prática eu resolvi ass atividades deixadas na aula por ele.

3. Conclusão

Achei muito interessante todos os videos, ele repetiu algumas coisas já abordadas antes mas de uma forma mais rápida e se aprofundou um pouco mais nelas, as técnicas são muito intuitivas e faceis de aprender, o professor tem uma didática boa e exemplos muito bons, gostei da aula e esses conhecimentos serao muito importantes no futuro.