

Relatório 12 - Prática: Pipelines de Dados I - Airflow (II)

João Pedro Gomes

1. Introdução

O card 12 pede pra vermos uma sequencia de videos sobre apache airflow e depois escrever esse relatório e realizar uma atividade pratica pra exercitar o aprendizado.

2. Desenvolvimento

O apache airflow é uma ferramenta usada pra automatizar tarefas, ela agenda, organiza pipelines de dados, vai ficar mais simples se eu der um exemplo:

Todo dia alguém tem que pegar dados de um lugar, tratar e salvar em outro lugar, o airflow define a ordem e os horarios de cada uma das tarefas. E pra isso o airflow tem 5 partes:

- Web Server: é a interface do airflow
- Scheduler: ele ve as dags ve quando rodar
- Metadata: é um banco onde guarda os dados do airflow, historico e uma log de tudo q esse airflow já fez
- Executor: ele ve como as tasks do airflow vao rodar, se é uma por vez, varias ao mesmo tempo
- Worker: é quem executa as tasks, o executor mandar e o worker faz

Depois ele explica sobre os key conceots do airflow.

- Dag: é o fluxo das tarefas junto com a ordem de execução, em inglês DAG é Directed Acyclic Graph, que quer dizer que tem uma ordem e no tem loops e graph que vem de grafo onde o conjunto de tarefas é tido com vertices e arestas, é definida no python, e ela não executa nada ela só e lida pelo airflow
- Operator: é uma classe em python que define oque vai ser executado e como, exemplos são o BashOperator que dita que vai rodar um comando no terminal
- Task: ele é um operator dentro de uma dag, ela define id, qual o operador e os parametros

- Task Instance: roda a task, ela tem o estado que é failed, success, running e queued, as tentativas de rodar ela q salva quantas vezes ela tentou rodar, tem logs e salva o tempo de execução
- Workflow: é o pipeline inteiro rodando, o sistema funcionando basicamente

Com o tempo a quantidade de tarefas pro airflow fazer aumenta e dependendo do computador ele não aguenta pra isso existe o multi-node, onde cada componente do airflow esta em uma maquina separada, diferente do single node que é tudo em um pc só.

Depois ele ensina alguns comandos do airflow:

Comando	Oque faz
airflow db init	Cria o banco
airflow db reset	Reseta o banco
airflow db upgrade	Atualiza o banco
airflow webserver	UI do airflow
airflow scheduler	Agenda do airflow
airflow worker	Executa a task
airflow dags list	Lista de Dags
airflow tasks list id_dag	Lista de tasks de uma dag

Aí ele começa a fazer a pratica principalmente no `forex_data_pipeline`, irei explicar um pouco sobre esse arquivo.

É um código feito pra automatizar a coleta, procesamento e notificar dados de cambio de moedas, todo dia ele verifica se tudo tá disponivel, como a API de taxas de cambio e um arquivo `.csv` com as moedas que vao ser avaliadas, depois ele pega os dado acessando a API pegando as taxas e salva num JSON depois são enviados pro HDFS q estrutura e depois armazena criando uma tabela no hive que é um sistema usado pra consultar bancos com muitos dados, usa o spark pra analisar a transformacao dos dados e finalizando o sistema envia notificacao por e-mail e slack avisando se tudo foi rodado certinho ou teve algum erro.

E também ele fala sobre execução usando o `start_date` e o `schedule_interval`:

`Start_date` e a data que ele comeca a agendar todas as execucoes

`Schedule_interval`: De quanto em quanto tempo a DAG vai rodar se for de 10 de minutos ela so roda depois de completar os 10 minutos, por exemplo, o start date e as 10 da manha a 1 dag vai rodar as 10:10 e pela 2 vez as 10:20

Depois ele aborda o dag run e o catchup, o dag run é a execução independente, a execução da mesma dag de ontem é diferente da que foi executada hoje, na log elas são coisas diferentes e independentes e o catchup é se a DAG ficou pausada por algum tempo o airflow ve isso e se o catchup tiver True ele pega todos os dias que a DAG não rodou e roda elas ao mesma tempo mas com a data do dia que ela não rodou e isso pode ser um problema que pra evitar é só deixar False.

Pratica:

Pra pratica eu fiz uma DAG que pega as musicas dos beatles, formata e printa na log do airflow.

3. Conclusão

O airflow é muito importantante pois ele automatiza muitas tarefas chatas e monotonas, eu achei bem facil de mexer com ele, instalar e entender os conceitos, espero que no futuro eu possa utilizar ele no meu dia a dia, pois gostei muito de mexer com a programacao de dag mesmo tendo feito bem pouco e algo bem simples.